

概率论初步

Ehundategu

Gioush 大队


2026 年 7 月



概率的基本概念

条件概率与 Bayes 公式

随机变量、期望与方差



概率的基本概念

样本空间与事件

概率与古典概型

例题

条件概率与 Bayes 公式


随机变量、期望与方差



Lead In

抛一枚均匀硬币，我们当然不知道哪一面会朝上。但是多抛一些，我们又会发现正面出现的比例逐渐靠近 $\frac{1}{2}$ 。

概率论要研究的就是这种随机现象。现在我们先回答两个问题：一次试验可能出现哪些结果？其中哪些结果是我们关心的？




Definition

定义

在相同条件下可以重复进行、结果不止一种，并且进行试验前不能确定具体结果的过程，称为随机试验。

例如抛一枚硬币、掷一枚骰子、从洗匀的牌堆中抽一张牌，都是随机试验。

注意，随机试验的条件和全部可能结果都要能够预先说明，只是我们无法提前知道实际发生哪一个结果。



Definition

定义

随机试验的每一个可能结果称为样本点。所有样本点构成的集合称为样本空间，记为 Ω 。

掷一枚六面骰子时，可以写成

$$\Omega = \{1, 2, 3, 4, 5, 6\}.$$

连续抛两次硬币时，必须保留先后顺序，因此

$$\Omega = \{\text{正正}, \text{正反}, \text{反正}, \text{反反}\}.$$

所以样本点怎么定义，后面就要数什么。



Definition

定义

样本空间 Ω 的子集称为随机事件，简称事件。事件 A 发生，指实际出现的样本点属于 A 。

掷骰子时，事件“点数为偶数”可以记为

$$A = \{2, 4, 6\}.$$

全集 Ω 称为必然事件，空集 $\emptyset$ 称为不可能事件。它们分别在每次试验中一定发生与一定不发生。




Theory

事件本身是集合，因此可以直接使用集合运算：

事件	含义
$A \cup B$	A, B 至少有一个发生
$A \cap B$	A, B 同时发生
$A \setminus B$	A 发生而 B 不发生
$\overline{A} = \Omega \setminus A$	A 不发生

若 $A \cap B = \emptyset$ ，称 A, B 互斥。注意，互斥只管两个事件能否同时发生，和它们各自的概率大小无关。



Definition

定义

对样本空间中的每个事件 A ，给出一个实数 $P(A)$ ，称为事件 A 的概率。它满足：

1. $P(A) \geq 0$ 。
2. $P(\Omega) = 1$ 。
3. 若 $A \cap B = \emptyset$ ，则

$$P(A \cup B) = P(A) + P(B).$$

前两条给出了概率的范围和总量。第三条告诉我们，如果两个事件没有重叠部分，那么它们的概率可以直接相加。



Proof

我们先来求不可能事件的概率。因为 $\Omega \cap \emptyset = \emptyset$ ，而且 $\Omega \cup \emptyset = \Omega$ ，根据可加性，

$$P(\Omega) = P(\Omega) + P(\emptyset),$$

所以

$$P(\emptyset) = 0.$$

接着来看事件 A 和它的对立事件 $\bar{A}$ 。它们满足

$$A \cap \bar{A} = \emptyset, \quad A \cup \bar{A} = \Omega.$$

所以

$$P(A) + P(\bar{A}) = P(\Omega) = 1,$$

整理一下就得到 $P(\bar{A}) = 1 - P(A)$ 。



Theory

定理 (单调性)

若 $A \subseteq B$, 则 $P(A) \leq P(B)$ 。

特别地, $\emptyset \subseteq A \subseteq \Omega$, 所以任意事件都满足

$$0 \leq P(A) \leq 1.$$



Proof

证明.

因为 $A \subseteq B$, 事件 A 与 $B \setminus A$ 互斥, 而且

$$B = A \coprod (B \setminus A).$$

于是

$$P(B) = P(A) + P(B \setminus A).$$

又因为 $P(B \setminus A) \geq 0$, 所以 $P(B) \geq P(A)$. □



Theory

定理 (概率的加法公式)

对于任意两个事件 A, B , 有

$$P(A \cup B) = P(A) + P(B) - P(A \cap B).$$

为什么要减去 $P(A \cap B)$? 因为直接计算 $P(A) + P(B)$ 时, 交集
中的结果会被计算两次。



Proof

证明.

我们把 $A \cup B$ 拆成三个两两互斥的部分:

$$A \cup B = (A \setminus B) \coprod (A \cap B) \coprod (B \setminus A).$$


同时,

$$P(A) = P(A \setminus B) + P(A \cap B),$$

$$P(B) = P(B \setminus A) + P(A \cap B).$$

把后两式相加, 交集恰好出现两次。对比第一式, 减去一次 $P(A \cap B)$ 即可。





Definition

定义

若一个随机试验的样本空间只含有限个样本点，并且每个样本点出现的概率相同，就称这个试验构成古典概型。

设 Ω 中共有 N 个样本点。它们等可能，而且概率之和为 1，所以每个样本点的概率都是 $\frac{1}{N}$ 。

注意，“有限”和“等可能”两个条件都要检查。只有结果数有限，还不能直接套用下面的公式。




Theory

定理 (古典概型的概率)

在古典概型中, 事件 A 的概率为

$$P(A) = \frac{n(A)}{n(\Omega)}.$$

所以在古典概型中, 求概率就转化成了计数: 分母数全部结果, 分子数使事件发生的结果。



Proof

证明.

设 $n(\Omega) = N$ 。每个样本点的概率都是 $\frac{1}{N}$ ，而事件 A 中有 $n(A)$ 个样本点。根据可加性，

$$P(A) = n(A) \cdot \frac{1}{N} = \frac{n(A)}{n(\Omega)}.$$






Method

现在总结一下古典概型的处理步骤：

1. 明确一个样本点究竟记录什么。
2. 验证样本点有限且等可能。
3. 计算样本空间中的样本点个数 $n(\Omega)$ 。
4. 把目标翻译为事件 A ，计算 $n(A)$ 。

这里最容易出问题的是样本点的定义。是否放回、是否保留顺序、元素能否重复，都会改变样本空间。把这些问题确定下来以后，再使用组合公式计数。




Example

P2911 [USACO08OCT] Bovine Bones G

有三枚均匀骰子，面数分别为 S_1, S_2, S_3 ，每枚骰子各面的点数从 1 开始连续编号。三枚骰子各掷一次，求出现概率最大的点数和。

若有多个点数和的概率相同，输出其中最小的一个。



Analyse

一次试验的结果可以记为三元组 (a, b, c) , 其中

$$1 \leq a \leq S_1, \quad 1 \leq b \leq S_2, \quad 1 \leq c \leq S_3.$$

三枚骰子相互独立, 而且每一面等可能, 所以这些三元组等可能, 样本空间大小为

$$n(\Omega) = S_1 S_2 S_3.$$



Analyse

对于每个可能的点数和 s ，记事件

$$A_s = \{(a, b, c) \mid a + b + c = s\}.$$

根据古典概型，

$$P(A_s) = \frac{n(A_s)}{S_1 S_2 S_3}.$$

所有概率的分母相同，所以比较 $P(A_s)$ ，只需要比较满足 $a + b + c = s$ 的三元组个数。



Analyse

最直接的方法是枚举所有三元组 (a, b, c) ，并把点数和 $a + b + c$ 的出现次数加一。题目中的面数很小，三元组总数至多为

$$20 \cdot 20 \cdot 40 = 16000.$$

最后从小到大检查 $s = 3, 4, \dots, S_1 + S_2 + S_3$ ，第一次达到最大次数的 s 就是答案。

时间复杂度为 $O(S_1 S_2 S_3)$ 。这道题把“比较概率”直接转化成了“统计等可能结果的个数”。



Summary

- ▶ 样本空间列出一次试验的全部可能结果，事件是其中的子集。



Summary

- ▶ 样本空间列出一次试验的全部可能结果，事件是其中的子集。
- ▶ 概率满足非负性、规范性与互斥可加性，其余常用公式都可以由此推出。




Summary

- ▶ 样本空间列出一次试验的全部可能结果，事件是其中的子集。
- ▶ 概率满足非负性、规范性与互斥可加性，其余常用公式都可以由此推出。
- ▶ 古典概型要求结果有限且等可能。



Summary

- ▶ 样本空间列出一次试验的全部可能结果，事件是其中的子集。
- ▶ 概率满足非负性、规范性与互斥可加性，其余常用公式都可以由此推出。
- ▶ 古典概型要求结果有限且等可能。
- ▶ 求概率时先建模，再计算总结果数与目标事件结果数。



概率的基本概念


条件概率与 Bayes 公式

条件概率与独立性

全概率与 Bayes

例题


随机变量、期望与方差



Lead In

袋中有 2 个红球与 3 个蓝球，不放回地连续抽取两个球。第一次抽到红球的概率是 $\frac{2}{5}$ 。如果已经知道第一次抽到了红球，那么第二次抽到红球的概率就变成了 $\frac{1}{4}$ 。

为什么概率发生了变化？因为“第一次抽到红球”排除了一部分原来可能的情况。条件概率处理的就是这类问题：已知事件 B 发生，再求事件 A 的概率。




Definition

定义

设 A, B 为两个事件, 且 $P(B) > 0$ 。在事件 B 已经发生的条件下, 事件 A 发生的条件概率定义为

$$P(A | B) = \frac{P(A \cap B)}{P(B)}.$$

也可以这样理解: 已知 B 发生后, 我们只需要看集合 B 。其中属于事件 A 的部分就是 $A \cap B$, 所以条件概率等于这部分在 B 中所占的比例。



Theory

定理 (条件概率的乘法公式)


若 $P(B) > 0$, 则

$$P(A \cap B) = P(B)P(A \mid B).$$

若 $P(A) > 0$, 也有

$$P(A \cap B) = P(A)P(B \mid A).$$

这个公式适合计算一条过程路径的概率：先到达前一阶段，再在这个条件下到达下一阶段。



Proof

证明.


由条件概率的定义,

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)}.$$

因为 $P(B) > 0$, 等式两边同乘 $P(B)$, 得到

$$P(A \cap B) = P(B)P(A \mid B).$$

交换 A, B 的位置, 再使用 $A \cap B = B \cap A$, 第二个等式同理可得。□



Definition


定义

若事件 A, B 满足

$$P(A \cap B) = P(A)P(B),$$

就称 A, B 相互独立。

当 $P(B) > 0$ 时，独立性等价于 $P(A | B) = P(A)$ 。换句话说，知道 B 已经发生以后，事件 A 的概率没有变化。



Theory


这里很容易把互斥和独立混在一起，我们对照来看：

- ▶ 互斥： $A \cap B = \emptyset$ ，两个事件不能同时发生。
- ▶ 独立： $P(A \cap B) = P(A)P(B)$ ，知道一个事件发生不会改变另一个事件的概率。

若 $P(A) > 0, P(B) > 0$ 且 A, B 互斥，则

$$P(A \cap B) = 0 < P(A)P(B),$$

所以它们一定不独立。只有概率为 0 的特殊情况，互斥和独立才可能同时出现。




Definition

定义

事件 $A_1, A_2, \dots, A_n$ 相互独立, 指对任意非空指标集合 $I \subseteq \{1, 2, \dots, n\}$, 都有

$$P\left(\bigcap_{i \in I} A_i\right) = \prod_{i \in I} P(A_i).$$

只检查任意两个事件, 得到的是两两独立。注意, 两两独立无法保证三个或更多事件同时独立, 所以定义中要检查所有非空指标集合。



Definition


定义

若事件 $B_1, B_2, \dots, B_n$ 两两互斥，满足

$$\bigsqcup_{i=1}^n B_i = \Omega,$$

并且每个 $P(B_i) > 0$ ，就称它们构成样本空间的一个完备事件组。

有了完备事件组，我们就把样本空间按照“来源”分成了若干类。任意事件 A 也会随之拆成若干个互斥部分。



Theory

定理 (全概率公式)

若 $B_1, B_2, \dots, B_n$ 构成完备事件组, 则对任意事件 A ,

$$P(A) = \sum_{i=1}^n P(B_i)P(A | B_i).$$

看这个公式, 我们对每一种来源分别计算 “选择该来源并发生 A ” 的概率, 最后把所有来源相加。



Proof

证明.

由于 $B_1, \dots, B_n$ 覆盖整个样本空间,

$$A = A \cap \Omega = A \cap \left(\prod_{i=1}^n B_i \right) = \prod_{i=1}^n (A \cap B_i).$$

这些事件两两互斥, 所以

$$P(A) = \sum_{i=1}^n P(A \cap B_i).$$

代入乘法公式 $P(A \cap B_i) = P(B_i)P(A | B_i)$, 即得结论。 □



Theory

定理 (Bayes 公式)

若 $B_1, \dots, B_n$ 构成完备事件组, 且 $P(A) > 0$, 则

$$P(B_j | A) = \frac{P(B_j)P(A | B_j)}{\sum_{i=1}^n P(B_i)P(A | B_i)}.$$

这里 $P(B_j)$ 是观察结果之前, 来源为 B_j 的概率。现在已经看到事件 A , 我们要用 $P(B_j | A)$ 重新计算这个概率。



Proof

证明.

根据条件概率与乘法公式,


$$P(B_j | A) = \frac{P(A \cap B_j)}{P(A)} = \frac{P(B_j)P(A | B_j)}{P(A)}.$$

再由全概率公式,

$$P(A) = \sum_{i=1}^n P(B_i)P(A | B_i).$$

把全概率公式代入分母, 就得到 Bayes 公式。





Example


Bayes 公式的直接计算

设 B_1, B_2 构成一个完备事件组, 并且

$$P(B_1) = \frac{1}{3}, \quad P(B_2) = \frac{2}{3},$$

$$P(A | B_1) = \frac{2}{3}, \quad P(A | B_2) = \frac{1}{4}.$$

求 $P(A)$ 与 $P(B_1 | A)$ 。




Analyse

我们先来计算事件 A 经过两种来源发生的概率。两条路径的概率分别为

$$P(B_1)P(A | B_1) = \frac{2}{9}, \quad P(B_2)P(A | B_2) = \frac{1}{6}.$$

注意, B_1, B_2 互斥, 而且它们的无交并覆盖整个样本空间。因此, $A \cap B_1$ 与 $A \cap B_2$ 也互斥, 并且覆盖事件 A 。




Analyse

根据全概率公式，

$$P(A) = \frac{1}{3} \cdot \frac{2}{3} + \frac{2}{3} \cdot \frac{1}{4} = \frac{7}{18}.$$

这里的两项分别对应事件 A 从 B_1 与 B_2 发生。每一个条件概率都要先乘上对应来源的概率。




Analyse

在事件 A 已经发生的条件下, 事件 B_1 发生的概率为


$$P(B_1 | A) = \frac{P(B_1)P(A | B_1)}{P(A)} = \frac{\frac{2}{9}}{\frac{7}{18}} = \frac{4}{7}.$$

观察事件 A 以前, B_1 的概率为 $\frac{1}{3}$ 。观察到 A 以后, 这个概率变为 $\frac{4}{7}$ 。这就是先验概率经过条件信息修正后得到后验概率。




Summary

- ▶ 条件概率把样本空间限制到已知事件。




Summary

- ▶ 条件概率把样本空间限制到已知事件。
- ▶ 沿一条过程路径使用乘法公式。



Summary

- ▶ 条件概率把样本空间限制到已知事件。
- ▶ 沿一条过程路径使用乘法公式。
- ▶ 对互斥且完备的来源使用全概率公式。




Summary

- ▶ 条件概率把样本空间限制到已知事件。
- ▶ 沿一条过程路径使用乘法公式。
- ▶ 对互斥且完备的来源使用全概率公式。
- ▶ 已知结果反推来源时使用 Bayes 公式。



Summary

- ▶ 条件概率把样本空间限制到已知事件。
- ▶ 沿一条过程路径使用乘法公式。
- ▶ 对互斥且完备的来源使用全概率公式。
- ▶ 已知结果反推来源时使用 Bayes 公式。
- ▶ 互斥描述“不能同时发生”，独立描述“信息不改变概率”。



概率的基本概念


条件概率与 Bayes 公式

随机变量、期望与方差

随机变量与期望

指示变量与方差


期望递推



Lead In

连续抛三次硬币，一共有八种完整结果。现在只关心“正面出现了多少次”，那么正正反、正反正、反正正都可以归到同一个数值 2。

于是我们给每个样本点赋上一个数值，得到随机变量。接下来要研究的就是这些数值如何分布、平均是多少、波动有多大。



Definition


定义

对于样本空间 Ω 中的每个样本点 ω ，都有唯一的实数 $X(\omega)$ 与之对应，我们称 X 为随机变量。若 X 的所有可能取值为有限个或可以一一列举，就称 X 为离散型随机变量。

设 X 表示连续抛三次硬币时正面出现的次数，则

$$X \in \{0, 1, 2, 3\}.$$

注意，随机变量是定义在样本空间上的函数。试验结果一旦确定， X 的值也随之确定。



Definition

定义

设离散型随机变量 X 的可能取值为 $x_1, x_2, \dots, x_n$ 。我们称


$$P(X = x_i) = p_i, \quad i = 1, 2, \dots, n$$

则称 $p_i, i = 1, 2, \dots, n$ 为 X 的概率分布列，简称分布列。

对于三次均匀抛硬币的正面次数，

X	0	1	2	3
P	$\frac{1}{8}$	$\frac{3}{8}$	$\frac{3}{8}$	$\frac{1}{8}$

这个分布列中的概率均非负，而且 $\sum_{i=0}^3 P(X = i) = 1$ 。



Definition

定义


设离散型随机变量 X 的分布列为 $P(X = x_i) = p_i$, $i = 1, 2, \dots, n$ 。我们称

$$E(X) = \sum_{i=1}^n x_i p_i$$

为随机变量 X 的均值或数学期望，数学期望简称期望。

也就是说，期望就是按照概率加权得到的平均值，它可以不在随机变量的取值中。例如均匀骰子的点数期望为

$$E(X) = \frac{1 + 2 + 3 + 4 + 5 + 6}{6} = \frac{7}{2}.$$



Theory

定理 (期望的仿射性质)

对常数 a, b , 有

$$E(aX + b) = aE(X) + b.$$

这个结论很直观：随机变量整体放大 a 倍，再平移 b ，期望也会做同样的变化。




Proof

证明.

若 X 取值为 x_i , 则 $aX + b$ 对应取值为 $ax_i + b$. 因此

$$\begin{aligned} E(aX + b) &= \sum_i (ax_i + b)P(X = x_i) \\ &= aE(X) + b \sum_i P(X = x_i). \end{aligned}$$

最后一个概率和等于 1, 所以结论成立。 □




Theory

定理 (期望的线性性)

若随机变量 X, Y 的期望存在, 则

$$E(X + Y) = E(X) + E(Y).$$

这里最重要的一点是, X, Y 无须独立。遇到一个难以直接求分布的总量, 我们可以把它拆成许多局部贡献, 分别求期望后再相加。




Proof

设 X, Y 的可能取值分别为 x, y 。按照二者的联合取值求和，

$$\begin{aligned} E(X + Y) &= \sum_x \sum_y (x + y) P(X = x, Y = y) \\ &= \sum_x x \sum_y P(X = x, Y = y) \\ &\quad + \sum_y y \sum_x P(X = x, Y = y). \end{aligned}$$

固定 x ，再对所有 y 求和，得到的就是 $P(X = x)$ 。另一部分同理，所以

$$E(X + Y) = E(X) + E(Y).$$



Definition

定义


事件 A 的指示变量定义为

$$I_A = \begin{cases} 1, & A \text{ 发生}, \\ 0, & A \text{ 不发生}. \end{cases}$$

它的期望为

$$E(I_A) = 1 \cdot P(A) + 0 \cdot P(\bar{A}) = P(A).$$

这样一来，“某件事发生了多少次”就可以写成若干个指示变量之和，再使用期望线性性处理。




Example

随机排列的不动点

从 $1, 2, \dots, n$ 的所有排列中等概率选取一个。若排列后数字 i 仍然位于第 i 个位置，就称 i 是一个不动点。

求这个随机排列中不动点个数的期望。



Analyse

对每个位置 i , 定义指示变量


$$I_i = \begin{cases} 1, & i \text{ 是不动点,} \\ 0, & \text{其他情况.} \end{cases}$$

若 X 表示不动点总数, 则

$$X = \sum_{i=1}^n I_i.$$

固定位置 i 后, 数字 i 等可能地出现在 n 个位置之一, 所以

$$P(I_i = 1) = \frac{1}{n}.$$




Analyse

利用期望线性性，

$$E(X) = \sum_{i=1}^n E(I_i) = \sum_{i=1}^n P(I_i = 1) = n \cdot \frac{1}{n} = 1.$$

注意，不同位置成为不动点的事件具有相关性。一个位置已经固定以后，剩余位置的排列空间会发生变化。不过期望线性性无须独立，所以我们不需要计算不动点总数的完整分布。

因此，遇到计数的期望时，可以先尝试把总量拆成若干个容易判断的指示变量。



Definition


定义

设离散型随机变量 X 的分布列为 $P(X = x_i) = p_i$, $i = 1, 2, \dots, n$ 。我们称

$$D(X) = \sum_{i=1}^n (x_i - E(X))^2 p_i$$

为随机变量 X 的方差。

期望给出了随机变量的平均位置。现在还要描述它在平均位置附近波动得有多大，于是定义方差。这里使用偏差的平方，使正负偏差不会相互抵消。




Theory

定理 (方差的计算公式)

$$D(X) = E(X^2) - (E(X))^2.$$

实际计算时，我们一般先求 $E(X)$ 和 $E(X^2)$ ，再代入这个公式。



Proof


证明.

把定义展开, 并把常数 $E(X)$ 记为 μ :

$$\begin{aligned}
 D(X) &= \sum_{i=1}^n (x_i - \mu)^2 p_i \\
 &= \sum_{i=1}^n x_i^2 p_i - 2\mu \sum_{i=1}^n x_i p_i + \mu^2 \sum_{i=1}^n p_i \\
 &= E(X^2) - 2\mu E(X) + \mu^2 \\
 &= E(X^2) - \mu^2.
 \end{aligned}$$

代回 $\mu = E(X)$ 即得结论。





Definition

定义


随机变量 X, Y 的协方差定义为

$$\text{Cov}(X, Y) = E((X - E(X))(Y - E(Y))).$$

展开后可以得到

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y).$$

这里引入协方差，是为了写出和的方差。后面只使用它的定义和上面的展开式。




Theory

定理 (和的方差)

$$D(X + Y) = D(X) + D(Y) + 2 \operatorname{Cov}(X, Y).$$

特别地, 若 X, Y 独立, 则

$$D(X + Y) = D(X) + D(Y).$$



Proof


令 $\mu = E(X), \nu = E(Y)$ 。直接展开定义，

$$\begin{aligned} D(X+Y) &= E(((X-\mu) + (Y-\nu))^2) \\ &= D(X) + D(Y) \\ &\quad + 2 \operatorname{Cov}(X, Y). \end{aligned}$$

若 X, Y 独立，则联合概率可以分解，因而

$$E(XY) = \sum_x \sum_y xy P(X=x)P(Y=y) = E(X)E(Y).$$

此时协方差为 0，方差可加。




Method

现在来看 OI 中更常见的期望递推。面对一个随机过程，我们从“下一步会发生什么”开始列方程，无须枚举所有完整过程：

1. 定义状态 E_i 的含义。
2. 写出终止状态的边界值。
3. 枚举下一步到达每个状态的概率。
4. 写成“一步代价 + 后继期望”。
5. 保留回到当前状态的项，再解出 E_i 。

注意自环。一些操作结束后状态没有变化，但是这一步已经执行，代价仍然要计算。




Theory

一般地，设状态 i 经过一步后，以概率 p_{ij} 到达状态 j ，这一步的代价为 1。若 E_i 表示从状态 i 到结束还需的期望步数，那么

$$E_i = 1 + \sum_j p_{ij} E_j.$$

如果其中包含 $j = i$ ，右侧就会出现 $p_{ii} E_i$ 。这就是自环项，我们把它移到左侧后再求解。




Example

灯潮往复 (flicker)

有 n 盏灯。第 i 盏灯的初始状态为 $a_i \in \{0, 1\}$ ，亮起时贡献亮度 w_i 。

有 m 个按钮，第 j 个按钮会把区间 $[l_j, r_j]$ 内所有灯的状态取反。实验进行 k 轮，每轮等概率选择一个按钮，各轮相互独立。求实验结束后总亮度的期望，并对 998 244 353 取模。



Analyse


一个直接想法是枚举 k 轮中每一轮按下的按钮。按钮序列共有 m^k 种，完整过程的数量随 k 指数增长。

我们保留朴素方法中“分别计算每盏灯贡献”的想法。定义指示变量

$$X_i = \begin{cases} 1, & \text{第 } i \text{ 盏灯最终亮起,} \\ 0, & \text{其他情况.} \end{cases}$$

若最终总亮度为 L ，那么

$$E(L) = \sum_{i=1}^n w_i E(X_i) = \sum_{i=1}^n w_i P(X_i = 1).$$



Analyse


记覆盖第 i 盏灯的按钮数为 c_i 。一轮中这盏灯被翻转的概率为

$$q_i = \frac{c_i}{m}.$$

令 $p_{i,t}$ 表示经过 t 轮后第 i 盏灯亮起的概率，初始时 $p_{i,0} = a_i$ 。

下一轮结束后，灯亮起有两种互斥情况：原来亮且没有被翻转，或者原来熄灭且被翻转。因此

$$p_{i,t+1} = p_{i,t}(1 - q_i) + (1 - p_{i,t})q_i.$$



Analyse

当 k 较小时, 可以按照 $t = 0, 1, \dots, k-1$ 逐轮递推。现在题目允许 k 很大, 我们来化简这个式子:


$$p_{i,t+1} = (1 - 2q_i)p_{i,t} + q_i.$$

它的不动点为 $\frac{1}{2}$ 。两边同时减去 $\frac{1}{2}$, 得到

$$p_{i,t+1} - \frac{1}{2} = (1 - 2q_i) \left(p_{i,t} - \frac{1}{2} \right).$$

连续递推 k 次以后,

$$p_{i,k} = \frac{1}{2} + \left(a_i - \frac{1}{2} \right) (1 - 2q_i)^k.$$



Analyse


代回期望线性性，

$$E(L) = \sum_{i=1}^n w_i \left[\frac{1}{2} + \left(a_i - \frac{1}{2} \right) \left(1 - \frac{2c_i}{m} \right)^k \right].$$

令模数 $M = 998\,244\,353$ 。因为 $m < M$ ，所以 m^{-1} 存在。计算时令

$$q_i \equiv c_i m^{-1} \pmod{M},$$

再把上面的加法、减法、乘法和整数次幂全部放在模 M 的意义下计算。




Analyse

现在把整个方法合在一起：

1. 用区间差分求出每个位置的覆盖次数 c_i 。
2. 计算 $q_i \equiv c_i m^{-1} \pmod{M}$ 。
3. 用快速幂求出 $(1 - 2q_i)^k$ ，再计算 $p_{i,k}$ 。
4. 累加每盏灯的期望贡献 $w_i p_{i,k}$ 。

时间复杂度为 $O(m + n \log k)$ ，空间复杂度为 $O(n)$ 。

有理数推导中的底数可能为负数，模意义下要先把 $1 - 2q_i$ 调整到 $[0, M)$ 。当 $k = 0$ 时，快速幂返回 1，公式会自然得到初始总亮度。




Summary

- ▶ 随机变量把每个随机结果映射为一个数值。



Summary

- ▶ 随机变量把每个随机结果映射为一个数值。
- ▶ 期望是按概率加权的平均值，线性性不要求独立。




Summary

- ▶ 随机变量把每个随机结果映射为一个数值。
- ▶ 期望是按概率加权的平均值，线性性不要求独立。
- ▶ 指示变量把计数问题转化为事件概率之和。



Summary

- ▶ 随机变量把每个随机结果映射为一个数值。
- ▶ 期望是按概率加权的平均值，线性性不要求独立。
- ▶ 指示变量把计数问题转化为事件概率之和。
- ▶ 方差刻画波动，独立随机变量的方差可以相加。



Summary

- ▶ 随机变量把每个随机结果映射为一个数值。
- ▶ 期望是按概率加权的平均值，线性性不要求独立。
- ▶ 指示变量把计数问题转化为事件概率之和。
- ▶ 方差刻画波动，独立随机变量的方差可以相加。
- ▶ 随机过程的期望从状态含义、边界和一步转移方程中得到。